

CLASSIFICATION

● I GUSTI NGURAH AGUNG HARI VIJAYA KUSUMA

Telephone
+62 81239327802

Address
Denpasar, Bali

site
www.agungg.com

August 2025



LATAR BELAKANG

Perusahaan telekomunikasi di era digital saat ini menghadapi tantangan besar dalam mempertahankan pelanggan. Salah satu permasalahan utama yang sering dihadapi adalah fenomena customer churn, yaitu kondisi ketika pelanggan memutuskan untuk berhenti berlangganan suatu layanan. Tingginya tingkat churn dapat berdampak signifikan terhadap pendapatan perusahaan, mengingat biaya untuk memperoleh pelanggan baru umumnya lebih tinggi dibandingkan mempertahankan pelanggan yang sudah ada. Memahami faktor-faktor yang mempengaruhi churn serta mampu memprediksi pelanggan mana yang berpotensi churn menjadi sangat penting bagi perusahaan sehingga perusahaan perlu membangun model prediksi churn yang efektif.



DATASET

TELECOM_CUSTOMER_CHURN

Dataset yang digunakan dalam tugas ini adalah dataset dalam format .csv yang berisi informasi langganan internet dari perusahaan telekomunikasi. Dataset ini mencakup berbagai informasi seperti customerid, jenis layanan, jenis kelamin, status pekerjaan, biaya langganan, dan informasi lainnya. Setiap baris dalam dataset mewakili satu pelanggan dan setiap kolom mewakili fitur-fitur tersebut. Adapun fitur dan label target dari dataset ini sebagai berikut:



FITUR DAN TARGET

TELECOM_CUSTOMER_CHURN

FITUR

Definisi masing-masing fitur

- Customerid: id dari customer
- Gender: gender dari customer
- Seniorcitizen: apakah merupakan senior citizen atau tidak
- Partner: apakah memiliki partner atau tidak
- Dependents: apakah memiliki tanggungan atau tidak seperti anak dll
- Tenure: tenure dari langganan customer
- PhoneService: apakah menggunakan layanan phone atau tidak
- MultipleLines: apakah menggunakan multiple lines atau tidak
- InternetService: Tipe dari internet service yang digunakan
- OnlineSecurity: apakah menggunakan fitur online security
- OnlineBackup: apakah menggunakan fitur online backup
- DeviceProtection: apakah menggunakan fitur device protection
- TechSupport: apakah menggunakan fitur tech support atau tidak

- StreamingTV: apakah menggunakan fitur streaming TV atau tidak
- StreamingMovies: apakah menggunakan fitur streaming film atau tidak
- Contract: tipe contract dari customer
- PaperlessBilling: apakah menggunakan fitur paperless billing atau tidak
- PaymentMethod: payment tipe yang digunakan oleh customer
- MonthlyCharges: total charges/biaya bulanan yang dibayarkan
- TotalCharges: total charges secara keseluruhan yang dibayarkan
- Churn: target variabel yang menunjukkan bahwa customer churn atau tidak

TARGET

- Churn: target variabel yang menunjukkan bahwa customer churn atau tidak

ANALISA & TEMUAN

PERBAIKAN DATA

Saya menemukan bahwa pada dataset terdapat fitur dengan tipe data yang kurang sesuai. Pada fitur totalcharges yang isi datanya bernilai numerik tapi memiliki tipe data Object, Sehingga perlu kita ubah menjadi float.

Setelah diubah ternyata terdapat 11 baris yang bernilai kosong. Namun karena data yang hilang tersebut sangat sedikit maka saya putuskan untuk membuang data tersebut.

25	15	Contract	7043	non-null	object
26	16	PaperlessBilling	7043	non-null	object
27	17	PaymentMethod	7043	non-null	object
28	18	MonthlyCharges	7043	non-null	float64
29	19	TotalCharges	7043	non-null	object
30	20	Churn	7043	non-null	object

12		
13	PaperlessBilling	0
14	PaymentMethod	0
15	MonthlyCharges	0
16	TotalCharges	11
17	Churn	0

ANALISA & TEMUAN

FITUR KATEGORIK

Pertama tama saya melakukan analisa fitur kategorik terlebih dahulu, dengan tujuan untuk melihat apakah fitur fitur yang ada di dataset memiliki hubungan yang signifikan dan merangking kekuatan hubungannya terlebih dahulu. Adapun metode chi square dipilih karena karena sesuai dengan konteks analisa ini yaitu menguji hubungan atau ketergantungan antara dua variabel kategorikal (Fitur dan Target)


Dengan mengetahui hubungan ini kita langsung bisa mengeliminasi fitur fitur yang tidak memiliki hubungan yang signifikan dengan label target. Walaupun kita sudah mengetahui fitur fitur yang mana saja yang signifikan namun kita tetap perlu melakukan analisa lebih lanjut untuk mengetahui kriteria customer seperti apa saja yang beresiko churn, dimana diharapkan dapat memberikan insight yang berguna bagi tim bisnis

Table 1: Hasil Uji Chi-Square

Nama Fitur	Chi-Squared	P-Value	Significant Association	Cramer's V
Contract	1179.55	7.33×10^{-257}	Ya	0.4096
TechSupport	824.93	7.41×10^{-180}	Ya	0.3425
OnlineSecurity	846.68	1.40×10^{-184}	Ya	0.3470
InternetService	728.70	5.83×10^{-159}	Ya	0.3219
PaymentMethod	645.43	1.43×10^{-139}	Ya	0.3030
OnlineBackup	599.18	7.78×10^{-131}	Ya	0.2919
DeviceProtection	555.88	1.96×10^{-121}	Ya	0.2812
StreamingMovies	374.27	5.35×10^{-82}	Ya	0.2307
StreamingTV	372.46	1.32×10^{-81}	Ya	0.2301
Dependents	186.32	2.02×10^{-42}	Ya	0.1628
SeniorCitizen	158.44	2.48×10^{-36}	Ya	0.1501
Partner	157.50	3.97×10^{-36}	Ya	0.1497
MultipleLines	11.27	0.0036	Ya	0.0400
PhoneService	0.87	0.35	Tidak	0.0111
Gender	0.48	0.49	Tidak	0.0082


APAKAH PELANGGAN YANG DENGAN CONTRACT KERJA TERTENTU CENDRUNG CHURN?

Dari Gambar dapat dilihat bahwa pelanggan dengan kontrak "Month-to-month" memiliki jumlah churn yang paling tinggi dibandingkan dengan kontrak "One year" dan "Two year". Hal ini menunjukkan bahwa pelanggan yang **memilih kontrak bulanan** cenderung lebih **sering berhenti** berlangganan dibandingkan dengan pelanggan yang memilih kontrak tahunan atau dua tahunan.




APAKAH PELANGGAN YANG MEMILIH LANGGANAN DENGAN PAKET BANTUAN TECHSUPPORT CENDRUNG CHURN?

Dari Gambar dapat dilihat bahwa pelanggan yang memilih untuk menggunakan layanan TechSupport memiliki jumlah churn yang lebih rendah dibandingkan dengan pelanggan yang tidak menggunakan layanan TechSupport. Hal ini menunjukkan bahwa layanan **TechSupport dapat** membantu **mengurangi** tingkat **churn** pelanggan.




APAKAH PELANGGAN YANG MEMILIH LAYANAN KEAMANAN ONLINE CENDRUNG CHURN?

Dari Gambar dapat dilihat bahwa pelanggan yang memilih untuk menggunakan layanan OnlineSecurity memiliki jumlah churn yang lebih rendah dibandingkan dengan pelanggan yang tidak menggunakan layanan OnlineSecurity. Hal ini menunjukkan bahwa **layanan OnlineSecurity** dapat membantu **mengurangi** tingkat **churn** pelanggan.




APAKAH PELANGGAN YANG MEMILIH LAYANAN INTERNET TERTENTU CENDRUNG CHURN?

Dari Gambar tersebut dapat dilihat bahwa pelanggan yang menggunakan layanan internet "Fiber optic" memiliki jumlah churn yang paling tinggi dibandingkan dengan pelanggan yang menggunakan layanan "DSL" atau tidak berlangganan internet. Hal ini menunjukkan bahwa pelanggan yang menggunakan layanan internet **Fiber optic** cenderung lebih **sering berhenti** berlangganan dibandingkan dengan pelanggan yang menggunakan layanan DSL atau tidak menggunakan layanan internet.



APAKAH PELANGGAN YANG MEMILIH METODE PEMBAYARAN TERTENTU CENDRUNG CHURN?

Dari Gambar dapat dilihat bahwa pelanggan yang menggunakan metode pembayaran "Electronic check" memiliki jumlah churn yang paling tinggi dibandingkan dengan metode pembayaran lainnya. Hal ini menunjukkan bahwa pelanggan yang menggunakan metode pembayaran **Electronic check** cenderung lebih **sering berhenti** berlangganan dibandingkan dengan pelanggan yang menggunakan metode pembayaran lainnya.




HEATMAP FITUR KATEGORIK



Dari Gambar berikut dapat dilihat bahwa terdapat beberapa fitur yang memiliki korelasi tinggi ditandai dengan warna yang lebih merah. Dan fitur fitur yang memiliki korelasi rendah ditandai dengan warna yang lebih biru. Adapun dengan temuan ini kita bisa melakukan feature selection untuk memilih fitur-fitur yang relevan dan tidak redundant. Kita akan memilih fitur-fitur yang memiliki korelasi tinggi dengan target variabel Churn dan menghindari fitur fitur yang memiliki korelasi tinggi satu sama lain.

Setelah ditelusuri beberapa fitur memang terlihat memiliki korelasi tinggi antara satu sama lain, namun karena banyak fitur yang memiliki korelasi lemah dengan target yaitu churn. Maka fitur fitur tersebut tetap disimpan karena saya takut kekurangan fitur saat melakukan modeling dan fokus untuk membuat decision untuk fitur fitur yang memiliki korelasi lemah dengan target.



INSIGHT

01 Jenis Contract Churn

Pelanggan dengan kontrak "Month-to-month" cenderung lebih sering berhenti berlangganan dibandingkan dengan pelanggan yang bekerja dengan kontrak tahunan atau dua tahunan.

02 Performa Layanan TechSupport Baik

Layanan TechSupport dapat membantu mengurangi tingkat churn pelanggan.

03 OnlineSecurity lebih bagus dari WindowsDefender

Layanan OnlineSecurity dapat membantu mengurangi tingkat churn pelanggan.

04 Fiber Optic Kenceng tapi Kemahalan

Pelanggan yang menggunakan layanan internet "Fiber optic" cenderung lebih sering berhenti berlangganan dibandingkan dengan pelanggan yang menggunakan layanan DSL atau tidak menggunakan layanan internet.

05 PaymentMethod

Pelanggan yang menggunakan metode pembayaran "Electronic check" cenderung lebih sering berhenti berlangganan dibandingkan dengan pelanggan yang menggunakan metode pembayaran lainnya.

SOLUSI

01 Fitur Contract

Perusahaan dapat melakukan penawaran khusus atau promosi untuk pelanggan yang masih bekerja dengan kontrak "Month-to-month" untuk meningkatkan retensi pelanggan.

02 Fitur TechSupport

Perusahaan dapat mempromosikan layanan TechSupport untuk membantu mengurangi tingkat churn pelanggan

03 Fitur OnlineSecurity

Perusahaan dapat mempromosikan layanan OnlineSecurity untuk membantu mengurangi tingkat churn pelanggan

04 Fitur InternetService

Perusahaan dapat mempertimbangkan untuk meningkatkan kualitas layanan internet Fiber optic untuk mengurangi tingkat churn pelanggan. Ataupun mengurangi biaya langganan untuk pelanggan yang menggunakan layanan internet Fiber optic.

05 Fitur PaymentMethod

Perusahaan dapat mempertimbangkan untuk menawarkan metode pembayaran yang lebih fleksibel kepada pelanggan yang menggunakan metode pembayaran Electronic check. ataupun bekerja sama dengan penyedia jasa pembayaran untuk promosi

ANALISA & TEMUAN

FITUR NUMERIK

Setelah di analisa fitur **tenure** nampaknya cocok untuk dilakukan **binning**, karena fitur ini merupakan fitur numerik yang memiliki informasi tentang lama berlangganan pelanggan. Kita akan melakukan binning pada fitur "tenure" untuk mengelompokkan pelanggan berdasarkan lama berlangganan mereka. Kita akan membuat 3 kelompok yaitu "0-12 bulan", "13-24 bulan", dan "25+bulan". Dengan begitu kita bisa melihat distribusi pelanggan berdasarkan lama berlangganan mereka.

Karena fitur tenure sudah kita putuskan untuk binning, maka selanjutnya kita akan cek tipe distribusi untuk fitur MonthlyCharges dan TotalCharges. Kita akan menggunakan histogram untuk melihat distribusi dari setiap fitur numerik.


Table 2: Ukuran Pemusatan Fitur Numerik

Statistik	Tenure	MonthlyCharges	TotalCharges
Count	7032	7032	7032
Mean	32.42	64.80	2283.30
Std Dev	24.55	30.09	2266.77
Min	1.00	18.25	18.80
25%	9.00	35.59	401.45
50%	29.00	70.35	1397.48
75%	55.00	89.86	3794.74
Max	72.00	118.75	8684.80

HEATMAP


FITUR NUMERIK

Dari Gambar dapat dilihat bahwa terdapat korelasi yang cukup tinggi antara fitur "MonthlyCharges" dan "TotalCharges", dengan nilai korelasi sekitar 0.65. Hal ini menunjukkan bahwa semakin tinggi biaya bulanan yang dibayarkan oleh pelanggan, semakin tinggi pula total biaya yang dibayarkan selama berlangganan. Sedangkan fitur "tenure" memiliki **korelasi** yang sangat tinggi dengan TotalCharges sekitar **0.83** sehingga salah satu dari fitur ini **akan di drop**. Karena kita memutuskan untuk binning fitur tenure maka kita akan mengdrop fitur TotalCharges



APAKAH PELANGGAN DENGAN BIAYA BULANAN TINGGI TOTAL BIAYA YANG TINGGI CENDERUNG CHURN?

Dari Gambar berikut mendapatkan bahwa pelanggan dengan biaya bulanan yang lebih tinggi cenderung untuk churn. Hal ini terlihat dari boxplot yang menunjukkan bahwa pelanggan yang churn memiliki biaya bulanan yang lebih tinggi dibandingkan dengan pelanggan yang tidak churn. Sedangkan untuk fitur "TotalCharges", kita tidak bisa menarik kesimpulan yang sama karena terlihat bahwa pelanggan dengan total biaya yang lebih sedikit yang churn.



INSIGHT

01 **Semakin Tinggi Tenure Semakin Tinggi Total Charges**

Pelanggan dengan lama berlangganan yang lebih lama cenderung memiliki total biaya yang lebih tinggi.

02 **Semakin Tinggi MonthlyCharges Semakin Tinggi Total Charges**

Pelanggan dengan biaya bulanan yang lebih tinggi cenderung memiliki total biaya yang lebih tinggi.

03 **Segmen 'Khusus' atau 'VIP'**

Terdapat segmen highend pada fitur TotalCharges menandakan adanya pelanggan yang memiliki total biaya yang sangat tinggi.

04 **Fitur MontlyCharges**

Pelanggan dengan biaya bulanan yang lebih tinggi cenderung untuk churn.

05 **Binning Tenure**

Fitur Tenure akan kita binning, dan setelah kita binning baru akan dilakukan analisis lebih dalam terkait fitur tersebut

SOLUSI

01 Fitur Tenure

Perusahaan dapat mempertimbangkan untuk memberikan penawaran khusus atau promosi kepada pelanggan dengan lama berlangganan yang lebih lama untuk meningkatkan retensi pelanggan.

02 Fitur MonthlyCharges


Perusahaan dapat mempertimbangkan untuk memberikan penawaran khusus atau promosi kepada pelanggan dengan biaya bulanan yang lebih tinggi untuk meningkatkan retensi pelanggan.

03 Fitur TotalCharges

Perusahaan dapat mempertimbangkan untuk melakukan segmentasi pelanggan berdasarkan total biaya yang dibayarkan untuk meningkatkan retensi pelanggan.


ANALISA FITUR TENURE

Fitur Tenure yang telah di binning selanjutnya di analisa, dari Gambar berikut dapat dilihat bahwa pelanggan yang memiliki lama berlangganan 0-12 bulan cenderung memiliki jumlah churn yang lebih tinggi dibandingkan dengan pelanggan yang memiliki lama berlangganan 13-24 bulan dan 25+bulan. Hal ini menunjukkan bahwa **pelanggan** yang **baru** berlangganan cenderung lebih sering **berhenti berlangganan** dibandingkan dengan pelanggan yang sudah lama berlangganan.



ANALISA FITUR ISMARRIED

Fitur SeniorCitizen, Dependents dan Partnet yang memiliki Chi Square yang kurang signifikan akan dilakukan binning dengan harapan fitur fitur ini dapat memberikan pola pola tidak terlihat yang ada dalam fitur tersebut. Dari Gambar berikut didapatkan bahwa setelah 3 fitur itu di binning dengan asumsi bahwa orang yang senior **atau** memiliki partner **atau** memiliki tanggungan yang dikategorikan **sudah menikah** lebih jarang churn ketimbang orang yang tidak senior **dan** tidak memiliki tanggungan **dan** tidak memiliki partner yang dikategorikan **belum menikah**



FITUR SELECTION

BERDASARKAN SEMUA ANALISA YANG TELAH DILAKUKAN

FITUR YANG AKAN DIBUANG

- Customerid: id dari customer
- Gender: gender dari customer
- Seniorcitizen: apakah merupakan senior citizen atau tidak
- Partner: apakah memiliki partner atau tidak
- Dependents: apakah memiliki tanggungan atau tidak seperti anak dll
- PhoneService: apakah menggunakan layanan phone atau tidak
- MultipleLines: apakah menggunakan multiple lines atau tidak
- TotalCharges: total charges secara keseluruhan yang dibayarkan

PREPROCESSING DAN HANDLING IMBALANCE DATA



01 > 2 Kategori

One-hot encoding adalah teknik yang mengubah setiap kategori menjadi kolom baru dengan nilai 0 atau 1. Adapun fitur yang cocok untuk dilakukan one-hot encoding adalah fitur kategorikal yang memiliki lebih dari 2 kategori.

02 = 2 Kategori

Adapun untuk fitur fitur yang hanya terdiri dari 2 kategoriseperti is married, kita akan mengubahnya menjadi 0 dan 1. Fitur ini akan diubah menjadi numerik dengan cara mengubah nilai "Yes" menjadi 1 dan "No" menjadi 0. Dengan begitu kita akan mendapatkan fitur-fitur yang siap digunakan dalam model klasifikasi.

1,78,0,1,0,1,0,1,0,0,0,0,1,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,0
0,20,0,3,0,0,1,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,0,1,0,0,0,1
0,20,0,1,0,0,1,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,1,0,0,0,0,1
1,105,1,3,0,1,0,1,0,0,0,0,1,0,0,1,1,0,0,0,0,1,0,0,1,0,0,1,1,0,0,0
1,105,0,3,0,1,0,1,0,0,0,0,1,0,0,1,1,0,0,0,0,1,0,0,1,1,0,0,0,0,1,0
0,24,1,3,0,0,1,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0
0,20,0,1,0,0,1,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,1,0,0,0,0,1
1,87,1,2,0,1,0,1,0,0,1,0,0,0,0,1,1,0,0,1,0,0,0,0,1,1,0,0,0,0,1,0
1,61,0,3,1,0,0,0,0,1,1,0,0,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,1,0,0
1,70,1,1,0,1,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,0,0,1,0
0,19,0,1,0,0,1,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,1,0,0,0,1,0,0
1,78,1,2,0,1,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,0,0,1,1,0,0,0,0,1,0
1,40,1,3,1,0,0,0,0,1,1,0,0,0,0,1,0,0,1,1,0,0,1,0,0,0,1,0,0,0,1,0
0,51,1,3,1,0,0,1,0,0,1,0,0,1,0,0,0,0,1,0,0,1,0,0,1,1,0,0,0,1,0,0
1,90,0,1,0,1,0,1,0,0,1,0,0,1,0,0,0,0,1,0,0,1,1,0,0,0,0,1,0,0,1,0
0,75,0,1,0,1,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,0,0,1
1,79,0,2,0,1,0,1,0,0,0,0,1,1,0,0,1,0,0,1,0,0,1,0,0,1,0,0,0,0,1,0

PREPROCESSING DAN HANDLING IMBALANCE

03 Numerik

Untuk fitur numerik, kita hanya memiliki 1 fitur yang perlu dilakukan preprocessing yaitu fitur MonthlyCharges. Namun karena ini adalah satu satunya fitur numerik yang ada dalam dataset, saya memutuskan untuk tidak melakukan preprocessing pada fitur ini. Kita akan menggunakan fitur ini apa adanya tanpa melakukan scaling atau normalisasi. Hal ini karena fitur ini merupakan satu satunya fitur numerik sehingga tidak ada fitur lain yang perlu diselaraskan dengan fitur ini.

02 Imbalance

Dari hasil distribusi kelas pada target variabel Churn, kita mendapatkan bahwa jumlah sampel pada kelas 0 (tidak churn) jauh lebih banyak dibandingkan dengan kelas 1 (churn). Hal ini menunjukkan bahwa data yang kita miliki tidak seimbang. Namun jika dihitung dari rasionya jumlah kelas 0 (tidak churn) adalah sekitar 73.8% dan jumlah kelas 1 (churn) adalah sekitar 26.2%. Hal ini menunjukkan bahwa data yang kita miliki masih dalam batas wajar untuk digunakan dalam model klasifikasi. Sehingga kita tetap perlu melakukan tuning pada model dengan menambahkan `class weight='balanced'` pada setiap model yang akan kita gunakan. Dengan begitu model akan memberikan bobot yang lebih besar pada kelas yang kurang terwakili yaitu kelas 1 (churn)

CLASSIFICATION

Setelah data siap maka kita akan melakukan modeling. Terdapat 4 model yang akan diuji dengan data yang telah kita persiapkan tadi diantaranya :

1. Logistic Regression
2. Decision Tree
3. Random Forest
4. XGBoost


HASIL CLASSIFICATION

Metrik	Logistic Regression	Decision Tree	Random Forest	XGBoost
Akurasi	72.4% / 71.7%	72.4% / 63.6%	74.9% / 70.8%	72.0% / 56.9%
Presisi	48.8% / 48.1%	48.5% / 41.3%	52.6% / 47.1%	48.2% / 37.7%
Recall	79.1% / 80.4%	58.8% / 87.2%	53.5% / 78.9%	69.5% / 94.9%
F1-score	60.4% / 60.4%	53.1% / 56.1%	53.0% / 58.9%	56.8% / 52.8%
ROC-AUC	0.8279 / 0.8279	0.6866 / 0.7880	0.7782 / 0.8216	0.7909 / 0.8276

MODEL DENGAN RECALL TERBAIK

Model XGBoost dengan hyperparameter tuning menunjukkan performa terbaik dalam hal recall, yaitu 94.9%, yang menunjukkan bahwa model ini sangat efektif dalam mendeteksi pelanggan yang berpotensi churn. Selain itu, nilai ROC-AUC juga tinggi, yaitu 0.8276, menunjukkan kemampuan model dalam membedakan antara pelanggan yang churn dan tidak churn.

Metode boosting secara konsisten memberikan kinerja recall yang lebih tinggi dibandingkan metode bagging maupun model tunggal (Decision Tree, Logistic Regression). Hal ini konsisten dengan karakteristik boosting yang fokus memperbaiki kesalahan prediksi sebelumnya, sehingga lebih efektif dalam mendeteksi pelanggan churn



Hyperparameter	Nilai yang diuji
n_estimators	200, 201, ..., 1000
learning_rate	0.001, 0.002, ..., 0.3
max_depth	3, 4, ..., 10
min_child_weight	1, 2, ..., 10
subsample	0.5, 0.6, ..., 1.0
colsample_bytree	0.5, 0.6, ..., 1.0
gamma	10 ⁻⁸ , 10 ⁻⁷ , ..., 10 ⁰
reg_alpha	10 ⁻⁸ , 10 ⁻⁷ , ..., 10 ⁰
reg_lambda	10 ⁻³ , 10 ⁻² , ..., 10 ²
scale_pos_weight	[1.5, 2.0] (dengan spw base)

Hyperparameter	Nilai Terbaik
colsample_bytree	0.8006
gamma	0.0046
learning_rate	0.0011
max_depth	4
min_child_weight	8
n_estimators	691
reg_alpha	0.3224
reg_lambda	0.0010
scale_pos_weight	5.5251
subsample	0.5917

KESIMPULAN

- Model XGBoost menunjukkan performa terbaik dalam hal recall, yaitu 94.9%, yang menunjukkan bahwa model ini sangat efektif dalam mendeteksi pelanggan yang berpotensi churn. Selain itu, nilai ROC-AUC juga tinggi, yaitu 0.8276, menunjukkan kemampuan model dalam membedakan antara pelanggan yang churn dan tidak churn.
- Model Decision Tree mengalami peningkatan recall yang signifikan setelah hyperparameter tuning, yaitu dari 58.8% menjadi 87.2%. Meskipun nilai ROC-AUC-nya tidak setinggi XGBoost, peningkatan ini menunjukkan bahwa model ini dapat dioptimasi lebih lanjut untuk meningkatkan performanya.
- Model Random Forest juga menunjukkan peningkatan recall yang signifikan, yaitu dari 53.5% menjadi 78.9%. Nilai ROC-AUC-nya juga meningkat, meskipun tidak sebesar Decision Tree.
- Model Logistic Regression memiliki performa yang stabil dengan recall sekitar 80.4% setelah hyperparameter tuning, namun tidak mengalami peningkatan yang signifikan dibandingkan model lainnya.
- Secara keseluruhan, model XGBoost adalah yang paling unggul dalam hal deteksi churn, diikuti oleh Decision Tree dan Random Forest. Logistic Regression memiliki performa yang baik, namun tidak sebaik model-model lainnya dalam konteks ini.
- Hyperparameter tuning terbukti efektif dalam meningkatkan performa model, terutama pada model Decision Tree, Random Forest, dan XGBoost. Hal ini menunjukkan pentingnya proses tuning untuk mendapatkan model yang optimal dalam konteks prediksi churn.
- Meskipun Logistic Regression memiliki performa yang baik, model ini mungkin tidak cukup kompleks untuk menangkap pola yang lebih rumit dalam data churn. Oleh karena itu, model berbasis pohon keputusan seperti Decision Tree, Random Forest, dan XGBoost lebih unggul dalam konteks ini.
- Metode boosting (XGBoost) secara konsisten memberikan kinerja recall yang lebih tinggi dibandingkan metode bagging (Random Forest) maupun model tunggal (Decision Tree, Logistic Regression). Hal ini konsisten dengan karakteristik boosting yang fokus memperbaiki kesalahan prediksi sebelumnya, sehingga lebih efektif dalam mendeteksi pelanggan churn.


REKOMENDASI BISNIS

BERDASARKAN INSIGHT EDA DAN HASIL CLASSIFICATION


- **Identifikasi Pelanggan Berisiko Churn:** Model XGBoost yang telah dioptimasi dapat digunakan untuk mengidentifikasi pelanggan yang berisiko tinggi untuk churn. Dengan mengetahui pelanggan mana yang berpotensi churn, perusahaan dapat mengambil tindakan proaktif untuk mempertahankan mereka.
- **Strategi Pemasaran yang Lebih Efektif:** Dengan informasi tentang pelanggan yang berisiko churn, perusahaan dapat merancang strategi pemasaran yang lebih efektif, seperti menawarkan diskon atau promosi khusus kepada pelanggan tersebut untuk mendorong mereka tetap menggunakan layanan.
- **Peningkatan Layanan Pelanggan:** Hasil analisis ini juga dapat digunakan untuk meningkatkan layanan pelanggan. Perusahaan dapat fokus pada peningkatan pengalaman pelanggan bagi mereka yang berisiko churn, sehingga dapat mengurangi tingkat churn.
- **Pengalokasian Sumber Daya yang Lebih Baik:** Dengan mengetahui pelanggan mana yang berisiko churn, perusahaan dapat mengalokasikan sumber daya dengan lebih efisien. Misalnya, perusahaan dapat mengarahkan tim layanan pelanggan untuk fokus pada pelanggan yang berisiko tinggi.

LAMPIRAN


Confusion Matrix - Best Logistic Regression Model




Confusion Matrix - Decision Tree (Tuned)




Confusion Matrix - Logistic Regression




Confusion Matrix (Test Set)




Confusion Matrix - Decision Tree (Baseline)




Confusion Matrix (Test Set)



Confusion Matrix



Confusion Matrix (Test Set)





THANK YOU

● FOR YOUR NICE ATTENTION

Telephone
+62 81239327802

Address
Denpasar, Bali

site
www.agungg.com

August 2025