

Homework Solution - Classification

I Gusti Ngurah Agung Hari Vijaya Kusuma Batch 57

August 10, 2025

Submission Links

- Repository: github.com/AgungHari

1 Pendahuluan

1.1 Latar Belakang

Perusahaan telekomunikasi di era digital saat ini menghadapi tantangan besar dalam mempertahankan pelanggan. Salah satu permasalahan utama yang sering dihadapi adalah fenomena *customer churn*, yaitu kondisi ketika pelanggan memutuskan untuk berhenti berlangganan suatu layanan. Tingginya tingkat churn dapat berdampak signifikan terhadap pendapatan perusahaan, mengingat biaya untuk memperoleh pelanggan baru umumnya lebih tinggi dibandingkan mempertahankan pelanggan yang sudah ada.

Memahami faktor-faktor yang mempengaruhi churn serta mampu memprediksi pelanggan mana yang berpotensi churn menjadi sangat penting bagi perusahaan. Dengan prediksi yang akurat, perusahaan dapat melakukan intervensi yang tepat, seperti memberikan penawaran khusus atau meningkatkan kualitas layanan, guna mencegah kehilangan pelanggan.

Melalui pemanfaatan data historis pelanggan, seperti data demografi, riwayat penggunaan layanan, dan perilaku pembayaran, teknologi *data science* dan *machine learning* memungkinkan perusahaan untuk membangun model prediksi churn yang efektif. Model ini dapat menjadi alat bantu pengambilan keputusan strategis, sehingga perusahaan dapat fokus pada segmen pelanggan yang paling berisiko churn dan merancang strategi retensi yang lebih efisien.

Tugas ini berfokus pada pembangunan model klasifikasi untuk memprediksi churn pelanggan pada perusahaan telekomunikasi berdasarkan berbagai fitur pelanggan. Diharapkan hasil dari proyek ini dapat memberikan insight dan rekomendasi bisnis yang relevan untuk meningkatkan retensi pelanggan.

1.2 Tujuan

Tujuan dari tugas ini adalah diantara lain untuk:

- Membangun model klasifikasi untuk memprediksi churn pelanggan pada perusahaan telekomunikasi.
- Menganalisis faktor-faktor yang berkontribusi terhadap churn pelanggan.
- Memberikan rekomendasi strategis untuk meningkatkan retensi pelanggan berdasarkan hasil analisis dan model yang dibangun.

1.3 Batasan atau Ruang Lingkup

Batasan masalah dalam tugas ini mencakup:

- Menggunakan dataset yang diberikan oleh rakamin.
- Penggunaan model klasifikasi untuk memprediksi churn.
- Analisis dilakukan pada fitur-fitur yang tersedia dalam dataset, tanpa melakukan pengumpulan data tambahan.

1.4 Manfaat

Manfaat dari tugas ini adalah membuat model klasifikasi yang dapat digunakan untuk memprediksi churn pelanggan.

2 Tinjauan Pustaka

2.1 Customer Churn

Customer churn, atau kehilangan pelanggan, adalah fenomena di mana pelanggan berhenti menggunakan layanan atau produk yang ditawarkan oleh suatu perusahaan. Hal ini menjadi perhatian utama bagi perusahaan, terutama di industri yang sangat kompetitif seperti telekomunikasi, karena churn dapat berdampak langsung pada pendapatan dan profitabilitas.

2.2 EDA (Exploratory Data Analysis)

Exploratory Data Analysis (EDA) adalah proses analisis data yang bertujuan untuk memahami struktur, pola, dan hubungan dalam dataset sebelum menerapkan model statistik atau machine learning. EDA melibatkan visualisasi data, statistik deskriptif, dan identifikasi anomali atau outlier. Proses ini penting untuk mendapatkan wawasan awal tentang data dan membantu dalam pengambilan keputusan selanjutnya.

2.3 Model Klasifikasi

Model klasifikasi adalah teknik dalam machine learning yang digunakan untuk mengelompokkan data ke dalam kategori atau kelas tertentu. Model ini dilatih menggunakan dataset yang berisi fitur-fitur input dan label output yang sesuai. Tujuan dari model klasifikasi adalah untuk memprediksi kelas dari data baru berdasarkan pola yang telah dipelajari dari data pelatihan.

2.4 Logistic Regression

Logistic regression adalah metode statistik yang digunakan untuk analisis regresi ketika variabel dependen bersifat kategorikal. Meskipun namanya mengandung kata "regression", logistic regression sebenarnya digunakan untuk klasifikasi. Metode ini memodelkan probabilitas suatu kejadian dengan menggunakan fungsi logit, yang mengubah output linear menjadi nilai antara 0 dan 1, sehingga cocok untuk prediksi kelas biner.

Untuk memahami logistic regression, kita perlu memahami konsep dasar dari regresi logistik. Regresi logistik digunakan untuk memprediksi probabilitas dari suatu kejadian yang bersifat biner (dua kelas), seperti churn atau tidak churn. Model ini mengasumsikan bahwa log odds dari probabilitas kejadian tersebut adalah linear terhadap fitur-fitur input.

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)}} \quad (1)$$

di mana:

- $P(Y = 1|X)$ adalah probabilitas bahwa kelas target Y adalah 1 (misalnya, churn).
- β_0 adalah intercept dari model.
- $\beta_1, \beta_2, \dots, \beta_n$ adalah koefisien regresi untuk fitur $X_1, X_2, \dots, X_n$.

- e adalah basis dari logaritma natural.
- $X_1, X_2, \dots, X_n$ adalah fitur-fitur input yang digunakan untuk memprediksi kelas target.

Dalam tugas ini apabila perhitungan probabilitas $P(Y=1|X)$ lebih besar dari 0.5 maka akan dikategorikan sebagai churn, sebaliknya jika kurang dari 0.5 maka tidak churn.

2.5 Random Forest

Random Forest adalah algoritma ensemble learning yang menggabungkan beberapa pohon keputusan (decision trees) untuk meningkatkan akurasi prediksi. Setiap pohon dalam hutan dibangun menggunakan subset acak dari data pelatihan dan fitur, sehingga mengurangi risiko overfitting yang sering terjadi pada pohon keputusan tunggal. Random Forest dapat digunakan untuk klasifikasi maupun regresi, dan memiliki keunggulan dalam menangani data besar dengan banyak fitur.

$$\hat{Y} = \frac{1}{N} \sum_{i=1}^N T_i(X) \quad (2)$$

di mana:

- $\hat{Y}$ adalah prediksi akhir dari Random Forest.
- N adalah jumlah pohon dalam hutan.
- $T_i(X)$ adalah prediksi dari pohon keputusan ke- i untuk input X .
- X adalah fitur-fitur input yang digunakan untuk memprediksi kelas target.
- $\sum_{i=1}^N T_i(X)$ adalah jumlah prediksi dari semua pohon dalam hutan.

2.6 XGBoost/Gradient Boosting

XGBoost (Extreme Gradient Boosting) adalah algoritma machine learning yang merupakan implementasi dari teknik gradient boosting. XGBoost dirancang untuk efisiensi, fleksibilitas, dan kinerja yang tinggi. Algoritma ini membangun model prediksi secara bertahap dengan menambahkan pohon keputusan baru yang mengoreksi kesalahan dari pohon sebelumnya. XGBoost sangat populer dalam kompetisi data science karena kemampuannya dalam menangani data besar dan kompleks.

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i) \quad (3)$$

di mana:

- $\hat{y}_i$ adalah prediksi untuk data ke- i .
- K adalah jumlah pohon dalam model XGBoost.

- $f_k(x_i)$ adalah output dari pohon ke- k untuk input x_i .
- x_i adalah fitur-fitur input yang digunakan untuk memprediksi kelas target.
- $\sum_{k=1}^K f_k(x_i)$ adalah jumlah prediksi dari semua pohon dalam model XGBoost.

2.7 Confusion Matrix

Confusion matrix merupakan salah satu pengukuran yang paling mudah dilakukan dalam mencari nilai tingkat kebenaran dan juga akurasi dari model. *Confusion matrix* adalah sebuah tabel berbentuk dua dimensi yang terdiri dari data aktual dan data prediksi yang masing-masing memiliki kelas. Data aktual terletak pada bagian kolom tabel, sedangkan data prediksi terletak pada bagian baris dari tabel. Gambar 1 merupakan representasi visual dari perhitungan confusion matrix.

		Predicted Class	
		1 (Positive)	0 (Negative)
Actual Class	1 (Positive)	TP (True Positive)	FN (False Negative) <i>Type II Error</i>
	0 (Negative)	FP (False Positive) <i>Type I Error</i>	TN (True Negative)

Gambar 1: Contoh Confusion Matrix

Confusion matrix memberikan informasi tentang jumlah prediksi yang benar dan salah untuk setiap kelas. Dari confusion matrix, kita dapat menghitung berbagai metrik evaluasi model seperti akurasi, presisi, recall, dan F1-score. Metrik-metrik ini membantu dalam menilai kinerja model klasifikasi secara keseluruhan.

2.8 Akurasi

Akurasi adalah metrik evaluasi yang mengukur seberapa baik model klasifikasi dalam memprediksi kelas yang benar. Akurasi didefinisikan sebagai rasio antara jumlah prediksi benar (true positives + true negatives) dengan jumlah total prediksi. Rumusnya adalah:

$$\text{Akurasi} = \frac{\text{True Positives} + \text{True Negatives}}{\text{Total Prediksi}} \quad (4)$$

di mana:

- True Positives (TP): Jumlah kasus positif yang benar-benar terdeteksi oleh model.

- True Negatives (TN): Jumlah kasus negatif yang benar-benar terdeteksi oleh model.
- Total Prediksi: Jumlah total kasus yang diprediksi oleh model, yaitu jumlah dari true positives, true negatives, false positives, dan false negatives.

Akurasi memberikan gambaran umum tentang kinerja model, tetapi dapat menjadi menyesatkan jika dataset tidak seimbang (misalnya, jika satu kelas jauh lebih banyak daripada kelas lainnya). Oleh karena itu, penting untuk mempertimbangkan metrik lain seperti recall dan precision untuk mendapatkan gambaran yang lebih lengkap tentang kinerja model.

2.9 Recall

Recall, juga dikenal sebagai sensitivitas atau true positive rate, adalah metrik evaluasi yang mengukur kemampuan model dalam mengidentifikasi kelas positif. Recall didefinisikan sebagai rasio antara jumlah prediksi benar positif (true positives) dengan jumlah total kasus positif aktual (true positives + false negatives). Rumusnya adalah:

$$\text{Recall} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}} \quad (5)$$

di mana:

- True Positives (TP): Jumlah kasus positif yang benar-benar terdeteksi oleh model.
- False Negatives (FN): Jumlah kasus positif yang tidak terdeteksi oleh model (salah diklasifikasikan sebagai negatif).

Recall sangat penting dalam konteks di mana kita ingin meminimalkan jumlah kasus positif yang terlewatkan, seperti dalam deteksi penyakit atau pencegahan churn pelanggan. Metrik ini memberikan gambaran tentang seberapa baik model dapat menangkap semua kasus positif yang sebenarnya ada.

2.10 Precision

Precision adalah metrik evaluasi yang mengukur akurasi dari prediksi positif yang dibuat oleh model. Precision didefinisikan sebagai rasio antara jumlah prediksi benar positif (true positives) dengan jumlah total prediksi positif (true positives + false positives). Rumusnya adalah:

$$\text{Precision} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}} \quad (6)$$

di mana:

- True Positives (TP): Jumlah kasus positif yang benar-benar terdeteksi oleh model.
- False Positives (FP): Jumlah kasus negatif yang salah diklasifikasikan sebagai positif oleh model.

Precision sangat penting dalam konteks di mana kita ingin meminimalkan jumlah prediksi positif yang salah, seperti dalam deteksi penipuan atau spam. Metrik ini memberikan gambaran tentang seberapa akurat model dalam mengidentifikasi kasus positif yang sebenarnya ada.

2.11 F1-Score

F1-Score adalah metrik evaluasi yang menggabungkan precision dan recall menjadi satu nilai tunggal. F1-Score dihitung sebagai harmonik rata-rata dari precision dan recall, sehingga memberikan keseimbangan antara kedua metrik tersebut. F1-Score sangat berguna ketika kita ingin mempertimbangkan trade-off antara precision dan recall, terutama dalam situasi di mana dataset tidak seimbang.

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (7)$$

di mana:

- Precision adalah rasio antara true positives dan total prediksi positif.
- Recall adalah rasio antara true positives dan total kasus positif aktual.
- F1-Score memberikan nilai antara 0 dan 1, di mana nilai 1 menunjukkan keseimbangan sempurna antara precision dan recall, sedangkan nilai 0 menunjukkan kinerja yang buruk.

F1-Score sangat berguna dalam konteks di mana kita ingin meminimalkan baik false positives maupun false negatives, seperti dalam deteksi penyakit atau klasifikasi teks. Metrik ini memberikan gambaran yang lebih komprehensif tentang kinerja model dibandingkan dengan precision atau recall secara terpisah.

2.12 ROC-AUC

ROC (Receiver Operating Characteristic) curve adalah grafik yang menunjukkan kinerja model klasifikasi biner pada berbagai ambang batas (threshold). ROC curve memplot true positive rate (TPR) terhadap false positive rate (FPR) pada berbagai nilai threshold. Area di bawah kurva ROC (AUC - Area Under the Curve) memberikan ukuran kinerja model secara keseluruhan.

AUC adalah nilai antara 0 dan 1, di mana nilai 1 menunjukkan model yang sempurna (mampu memisahkan kelas positif dan negatif dengan sempurna), sedangkan nilai 0.5 menunjukkan model yang tidak lebih baik dari tebakan acak. AUC yang lebih tinggi menunjukkan bahwa model memiliki kemampuan yang lebih baik dalam membedakan antara kelas positif dan negatif.

$$\text{AUC} = \int_0^1 \text{TPR}(\text{FPR}) d\text{FPR} \quad (8)$$

di mana:

- TPR (True Positive Rate) adalah rasio antara jumlah prediksi benar positif dengan jumlah total kasus positif aktual.
- FPR (False Positive Rate) adalah rasio antara jumlah prediksi salah positif dengan jumlah total kasus negatif aktual.

- Integral ini menghitung area di bawah kurva ROC, yang memberikan nilai AUC.
- Nilai AUC yang lebih tinggi menunjukkan bahwa model memiliki kemampuan yang lebih baik dalam membedakan antara kelas positif dan negatif.

2.13 Chi-Squared Test

Chi-Squared Test adalah metode statistik yang digunakan untuk menguji independensi antara dua variabel kategorikal. Uji ini membandingkan frekuensi yang diamati dalam kategori tertentu dengan frekuensi yang diharapkan jika kedua variabel tersebut independen. Chi-Squared Test sering digunakan dalam analisis data untuk menentukan apakah ada hubungan signifikan antara dua variabel.

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i} \quad (9)$$

di mana:

- χ^2 adalah nilai statistik Chi-Squared.
- O_i adalah frekuensi yang diamati untuk kategori ke-i.
- E_i adalah frekuensi yang diharapkan untuk kategori ke-i jika kedua variabel independen.
- Penjumlahan dilakukan untuk semua kategori yang ada.
- Nilai χ^2 yang lebih tinggi menunjukkan bahwa ada perbedaan signifikan antara frekuensi yang diamati dan yang diharapkan, yang mengindikasikan bahwa kedua variabel mungkin tidak independen.

2.14 Cramer's V

Cramer's V adalah ukuran asosiasi antara dua variabel kategorikal yang digunakan untuk mengukur kekuatan hubungan antara variabel tersebut. Nilai Cramer's V berkisar antara 0 hingga 1, di mana 0 menunjukkan tidak ada asosiasi dan 1 menunjukkan asosiasi sempurna. Cramer's V dihitung berdasarkan nilai Chi-Squared dan ukuran sampel.

Asosiasi adalah hubungan antara dua variabel yang dapat diukur dengan berbagai cara. Cramer's V adalah salah satu metode yang digunakan untuk mengukur kekuatan asosiasi antara dua variabel kategorikal. Nilai Cramer's V berkisar antara 0 hingga 1, di mana 0 menunjukkan tidak ada asosiasi dan 1 menunjukkan asosiasi sempurna.

$$V = \sqrt{\frac{\chi^2}{n \cdot \min(k-1, r-1)}} \quad (10)$$

di mana:

- V adalah nilai Cramer's V.
- χ^2 adalah nilai statistik Chi-Squared yang dihitung dari tabel kontingensi.

- n adalah ukuran sampel (jumlah total observasi).
- k adalah jumlah kategori pada variabel pertama.
- r adalah jumlah kategori pada variabel kedua.
- Nilai Cramer's V yang lebih tinggi menunjukkan asosiasi yang lebih kuat antara kedua variabel kategorikal.
- Jika $V = 0$, berarti tidak ada asosiasi antara kedua variabel, sedangkan jika $V = 1$, berarti ada asosiasi sempurna.

2.15 SelectKBest

SelectKBest adalah metode pemilihan fitur yang digunakan untuk memilih sejumlah fitur terbaik dari dataset berdasarkan skor statistik tertentu. Metode ini membantu dalam mengurangi dimensi data dengan memilih fitur-fitur yang paling relevan untuk model, sehingga meningkatkan kinerja dan interpretabilitas model. SelectKBest dapat digunakan dengan berbagai fungsi skor, seperti ANOVA F-value, chi-squared, atau mutual information.

Adapun penggunaan SelectKBest harus menggunakan data yang sudah dibagi menjadi data latih dan data uji. Hal ini penting untuk memastikan bahwa fitur yang dipilih tidak bias terhadap data uji, sehingga model yang dibangun dapat generalisasi dengan baik pada data baru.

$$\text{Score}(X, y) = \frac{1}{n} \sum_{i=1}^n f(X_i, y) \quad (11)$$

di mana:

- $\text{Score}(X, y)$ adalah skor fitur yang dihitung berdasarkan fungsi skor f .
- n adalah jumlah fitur yang ada.
- X_i adalah nilai dari fitur ke- i .
- y adalah label target (kelas) yang ingin diprediksi.
- Fungsi skor f dapat berupa ANOVA F-value, chi-squared, atau mutual information, tergantung pada jenis data dan tujuan analisis.
- Nilai skor yang lebih tinggi menunjukkan bahwa fitur tersebut lebih relevan untuk memprediksi label target.

3 Desain dan Implementasi

Tugas ini dilakukan sesuai dengan desain sistem berikut beserta implementasinya. Desain sistem adalah konsep dari pembuatan dan perancangan infrastruktur dan kemudian diwujudkan dalam bentuk alur yang harus dikerjakan

3.1 Deskripsi sistem

Pada tugas ini kita akan melakukan analisis data dan membangun model klasifikasi untuk memprediksi apakah pelanggan perusahaan telekomunikasi penyedia wifi akan berhenti berlangganan atau tidak. Dataset yang digunakan adalah dataset churn pelanggan yang berisi informasi tentang pelanggan, seperti jenis layanan, jenis kelamin, status pekerjaan, biaya langganan, dan informasi lainnya. Desain sistem ini mencakup langkah-langkah yang akan dijabarkan dalam Gambar 2.



Gambar 2: Desain Sistem

3.2 Feature Extraction

Feature extraction adalah proses mengidentifikasi dan memilih fitur-fitur yang relevan dari dataset yang akan digunakan dalam model klasifikasi. Dalam tugas ini, fitur-fitur yang dipilih mencakup informasi tentang pelanggan, seperti jenis layanan, jenis kelamin, status pekerjaan, biaya langganan, dan informasi lainnya.

3.2.1 Deskripsi Fitur

Dataset yang digunakan dalam tugas ini adalah dataset dalam format .csv yang berisi informasi langganan internet dari perusahaan telekomunikasi. Dataset ini mencakup berbagai informasi seperti customerid, jenis layanan, jenis kelamin, status pekerjaan, biaya langganan, dan informasi lainnya. Setiap baris dalam dataset mewakili satu pelanggan dan setiap kolom mewakili fitur-fitur tersebut. Gambar 3 merupakan contoh dari dataset yang digunakan.

customerid	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	MultipleLines	InternetService	OnlineSecurity	OnlineBackup	DeviceProtection	TechSupport	StreamingTV	StreamingMovies	Contract	PaperlessBilling	PaymentMethod	MonthlyCharges	TotalCharges	Churn
7590-WWEG	Female	0	Yes	No	1	No	No	phone service	DSL	No	Yes	No	No	No	Month-to-month	Yes	Electronic check	29.85	29.85	No
5575-QNVE	Male	0	No	No	34	Yes	No	DSL	Yes	No	Yes	No	No	No	One year	No	Mailed check	36.95	1889.5	No
3668-QP8K	Male	0	No	No	2	Yes	No	DSL	Yes	No	No	No	Month-to-month	Yes	Mailed check	53.85	108.15	Yes		
7795-CFOU	Male	0	No	No	45	No	No	phone service	DSL	Yes	No	Yes	No	No	One year	No	Bank transfer (automatic)	42.3	1840.75	No
9237-HQTL	Female	0	No	No	2	Yes	No	Fiber optic	No	No	No	No	Month-to-month	Yes	Electronic check	78.7	151.45	Yes		
9305-CDSC	Female	0	No	No	8	Yes	Yes	Fiber optic	No	No	Yes	No	Month-to-month	Yes	Electronic check	99.65	820.5	Yes		
1453-KIOVL	Male	0	No	Yes	22	Yes	Yes	Fiber optic	No	Yes	No	No	Month-to-month	Yes	Credit card (automatic)	89.1	1949.4	No		
8713-CKDM	Female	0	No	No	10	No	No	phone service	DSL	No	No	No	Month-to-month	No	Mailed check	29.75	301.3	No		
7892-POOKP	Female	0	Yes	No	25	Yes	Yes	Fiber optic	No	No	Yes	Yes	Month-to-month	Yes	Electronic check	104.8	3046.05	Yes		
6388-TABGU	Male	0	No	Yes	62	Yes	No	DSL	Yes	Yes	No	No	One year	No	Bank transfer (automatic)	56.15	3487.95	No		
9783-GRSKD	Male	0	Yes	Yes	13	Yes	No	DSL	Yes	No	No	No	Month-to-month	Yes	Mailed check	49.95	587.45	No		
7469-LBCKL	Male	0	No	No	16	Yes	No	No	Internet service	No	Internet service	No	Internet service	No	Two year	No	Credit card (automatic)	18.95	326.8	No
8091-TTVA	Male	0	Yes	No	58	Yes	Yes	Fiber optic	No	No	Yes	No	One year	No	Credit card (automatic)	100.35	5681.1	No		
0280-XJGX	Male	0	No	No	49	Yes	Yes	Fiber optic	No	Yes	Yes	No	Month-to-month	Yes	Bank transfer (automatic)	103.7	5036.3	Yes		

Gambar 3: Contoh Dataset Pelanggan

Adapun untuk memperjelas fitur-fitur yang akan dipilih dalam metode feature selection untuk model klasifikasi kita nantinya, berikut adalah deskripsi singkat dari beberapa fitur yang terdapat dalam dataset:

- Customerid: ID unik dari pelanggan.
- Gender: Jenis kelamin pelanggan (Pria/Wanita).
- Seniorcitizen: Apakah pelanggan merupakan senior citizen (1 untuk ya, 0 untuk tidak).
- Partner: Apakah pelanggan memiliki pasangan (Ya/Tidak).
- Dependents: Apakah pelanggan memiliki tanggungan (Ya/Tidak).
- Tenure: Lama berlangganan layanan (dalam bulan).
- PhoneService: Apakah pelanggan menggunakan layanan telepon (Ya/Tidak).
- MultipleLines: Apakah pelanggan menggunakan layanan telepon multiple lines (Ya/Tidak).
- InternetService: Tipe layanan internet yang digunakan (DSL/Fiber optic/No).
- OnlineSecurity: Apakah pelanggan menggunakan fitur keamanan online (Ya/Tidak).
- OnlineBackup: Apakah pelanggan menggunakan fitur backup online (Ya/Tidak).
- DeviceProtection: Apakah pelanggan menggunakan fitur perlindungan perangkat (Ya/Tidak).
- TechSupport: Apakah pelanggan menggunakan fitur dukungan teknis (Ya/Tidak).
- StreamingTV: Apakah pelanggan menggunakan fitur streaming TV (Ya/Tidak).
- StreamingMovies: Apakah pelanggan menggunakan fitur streaming film (Ya/Tidak).
- Contract: Tipe kontrak layanan (Month-to-month/One year/Two year).
- PaperlessBilling: Apakah pelanggan menggunakan penagihan tanpa kertas (Ya/Tidak).
- PaymentMethod: Metode pembayaran yang digunakan (Electronic check / Mailed check / Bank transfer (automatic) /Credit card (automatic)).
- MonthlyCharges: Biaya bulanan yang dibayarkan oleh pelanggan.
- TotalCharges: Total biaya yang dibayarkan oleh pelanggan selama berlangganan.
- Churn: Target variabel yang menunjukkan apakah pelanggan berhenti berlangganan (Ya/Tidak), dan merupakan Label target yang akan diprediksi oleh model klasifikasi.

3.3 EDA (Exploratory Data Analysis)

Exploratory Data Analysis (EDA) adalah proses analisis awal terhadap dataset untuk memahami struktur, pola, dan hubungan antar fitur. Dalam tugas ini, EDA dilakukan untuk mengidentifikasi karakteristik data, mendeteksi adanya missing values, outliers, dan distribusi dari setiap fitur.

Pertama tama yang kita akan lakukan adalah mengimport dataset dan menyiapkan library yang akan digunakan dalam EDA. Pandas, NumPy, Matplotlib, dan Seaborn adalah beberapa library yang umum digunakan untuk analisis data dan visualisasi di Python. Pandas digunakan untuk manipulasi data, NumPy untuk operasi numerik, Matplotlib dan Seaborn untuk visualisasi data.

Listing 1: Import Library dan Dataset

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5
6 # Import dataset
7 df = pd.read_csv('dataset.csv')
```

Setelah mengimport dataset, langkah selanjutnya adalah melakukan analisis awal terhadap data. Kita akan melihat beberapa informasi dasar tentang dataset, seperti jumlah baris dan kolom, tipe data dari setiap kolom, serta beberapa baris pertama dari dataset. Dengan menggunakan `.info` kita bisa melihat tipe data dari setiap kolom.

Listing 2: Informasi Awal Dataset

```
1 # Informasi awal dataset
2 df.info()
3
4 # Output
5 <class 'pandas.core.frame.DataFrame'>
6 RangeIndex: 7043 entries, 0 to 7042
7 Data columns (total 21 columns):
8 #    Column                Non-Null Count  Dtype
9 ---  -
10 0    customerID             7043 non-null   object
11 1    gender                 7043 non-null   object
12 2    SeniorCitizen          7043 non-null   int64
13 3    Partner                7043 non-null   object
14 4    Dependents             7043 non-null   object
15 5    tenure                 7043 non-null   int64
16 6    PhoneService           7043 non-null   object
17 7    MultipleLines          7043 non-null   object
18 8    InternetService        7043 non-null   object
19 9    OnlineSecurity         7043 non-null   object
20 10   OnlineBackup            7043 non-null   object
21 11   DeviceProtection       7043 non-null   object
```

```

22 12 TechSupport      7043 non-null object
23 13 StreamingTV      7043 non-null object
24 14 StreamingMovies  7043 non-null object
25 15 Contract          7043 non-null object
26 16 PaperlessBilling  7043 non-null object
27 17 PaymentMethod     7043 non-null object
28 18 MonthlyCharges    7043 non-null float64
29 19 TotalCharges      7043 non-null object
30 20 Churn             7043 non-null object
31 dtypes: float64(1), int64(2), object(18)
32 memory usage: 1.1+ MB

```

Setelah saya analisa ternyata terdapat beberapa kolom yang memiliki tipe data yang tidak sesuai, seperti kolom TotalCharges yang seharusnya bertipe numerik namun masih bertipe object. Hal ini bisa terjadi karena adanya missing values atau karakter non-numerik dalam kolom tersebut. Oleh karena itu, kita perlu melakukan pembersihan data untuk memastikan bahwa semua kolom memiliki tipe data yang sesuai.

Listing 3: Perbaikan Tipe Data Kolom TotalCharges

```

1 # Mengubah tipe data kolom TotalCharges menjadi numerik
2 df['TotalCharges'] = pd.to_numeric(df['TotalCharges'], errors='coerce')
3
4 # Mengecek missing values setelah perubahan tipe data
5 missing_values = df.isnull().sum()
6 print("Missing values after type conversion:\n", missing_values)
7
8 # Output
9 customerID      0
10 gender          0
11 .....
12 .....
13 PaperlessBilling  0
14 PaymentMethod    0
15 MonthlyCharges   0
16 TotalCharges     11
17 Churn            0
18 dtype: int64

```

Saya juga melakukan pengecekan terhadap missing values pada dataset. Dengan menggunakan `.isnull().sum()` kita bisa melihat jumlah missing values pada setiap kolom. Dari hasil pengecekan, terdapat 11 missing values pada kolom TotalCharges. Kita perlu menangani missing values ini sebelum melanjutkan analisis lebih lanjut.

Untuk menangani missing values pada kolom TotalCharges, kita bisa menghapus baris yang memiliki missing values tersebut atau mengisi missing values dengan nilai rata-rata atau median dari kolom tersebut. Dalam tugas ini, saya memilih untuk menghapus baris yang memiliki missing values.

Listing 4: Menghapus Missing Values

```

1 # output

```

```

2 .....
3 .....
4 MonthlyCharges      0
5 TotalCharges        0
6 Churn               0
7 dtype: int64

```

Kita telah selesai menghapus missing values pada kolom TotalCharges. Setelah itu, kita akan melakukan analisis lebih lanjut terhadap fitur-fitur yang ada dalam dataset. Kita akan melihat distribusi dari setiap fitur, hubungan antar fitur, serta outliers yang mungkin ada dalam dataset.

Agar memudahkan analisa maka dataset akan dibagi menjadi dua bagian, yaitu dataset untuk fitur numerik dan dataset untuk fitur kategorikal. Hal ini dilakukan agar analisis dapat dilakukan dengan lebih efektif.

Adapun pembagiannya sebagai berikut :

Listing 5: Memisahkan Fitur Numerik dan Kategorikal

```

1 Numerical Columns: ['tenure', 'MonthlyCharges', 'TotalCharges']
2 Categorical Columns: ['customerID', 'gender', 'SeniorCitizen',
3 'Partner', 'Dependents', 'PhoneService', 'MultipleLines',
4 'InternetService', 'OnlineSecurity', 'OnlineBackup',
5 'DeviceProtection', 'TechSupport', 'StreamingTV',
6 'StreamingMovies', 'Contract', 'PaperlessBilling',
7 'PaymentMethod', 'Churn']

```

3.3.1 Analisis Fitur Kategorikal

Analisis fitur kategorikal dilakukan untuk memahami distribusi dari setiap fitur kategorikal dalam dataset. Kita akan menggunakan visualisasi seperti bar plot untuk melihat jumlah pelanggan berdasarkan setiap kategori. Namun agar barplot tidak terlalu banyak kita akan uji dengan chi square terlebih dahulu untuk melihat fitur mana saja yang signifikan terhadap target variabel Churn. Dengan begitu kita bisa plot barplot hanya untuk fitur yang signifikan saja.

Setelah melakukan pengecekan menggunakan chi-square saya menemukan bahwa terdapat fitur-fitur yang signifikan terhadap target variabel Churn. Adapun Tabel 1 berikut adalah hasil dari uji chi-square yang dilakukan.

Table 1: Hasil Uji Chi-Square

Nama Fitur	Chi-Squared	P-Value	Significant Association	Cramer's V
Contract	1179.55	7.33×10^{-257}	Ya	0.4096
TechSupport	824.93	7.41×10^{-180}	Ya	0.3425
OnlineSecurity	846.68	1.40×10^{-184}	Ya	0.3470
InternetService	728.70	5.83×10^{-159}	Ya	0.3219
PaymentMethod	645.43	1.43×10^{-139}	Ya	0.3030
OnlineBackup	599.18	7.78×10^{-131}	Ya	0.2919
DeviceProtection	555.88	1.96×10^{-121}	Ya	0.2812
StreamingMovies	374.27	5.35×10^{-82}	Ya	0.2307
StreamingTV	372.46	1.32×10^{-81}	Ya	0.2301
Dependents	186.32	2.02×10^{-42}	Ya	0.1628
SeniorCitizen	158.44	2.48×10^{-36}	Ya	0.1501
Partner	157.50	3.97×10^{-36}	Ya	0.1497
MultipleLines	11.27	0.0036	Ya	0.0400
PhoneService	0.87	0.35	Tidak	0.0111
Gender	0.48	0.49	Tidak	0.0082

Dapat dilihat bahwa fitur yang memiliki nilai Chi-Squared yang tinggi dan p-value yang sangat kecil menunjukkan adanya hubungan yang signifikan dengan target variabel Churn. Fitur-fitur seperti Contract, TechSupport, OnlineSecurity, dan InternetService memiliki nilai Cramer's V yang cukup tinggi, menunjukkan bahwa fitur-fitur tersebut memiliki pengaruh yang signifikan terhadap keputusan pelanggan untuk berhenti berlangganan.


Sedangkan fitur dengan nilai Chi-Squared yang rendah dan p-value yang tinggi menunjukkan kebalikannya yaitu tidak ada hubungan yang signifikan terhadap label target variabel churn. Fitur-fitur seperti PhoneService dan Gender tidak menunjukkan hubungan yang signifikan dengan target variabel Churn, sehingga kita tidak perlu melakukan analisis lebih lanjut terhadap fitur-fitur tersebut.

Setelah mengetahui fitur-fitur yang signifikan, kita akan melakukan visualisasi untuk melihat distribusi dari setiap fitur kategorikal yang signifikan terhadap target variabel Churn. Kita akan menggunakan bar plot untuk melihat jumlah pelanggan berdasarkan setiap kategori.

Adapun pertanyaan yang ingin saya jawab untuk analisis fitur kategorikal ini adalah sebagai berikut:

- Apakah pelanggan yang dengan contract kerja tertentu cenderung churn?
- Apakah pelanggan yang memilih langganan dengan paket bantuan TechSupport cenderung churn?
- Apakah pelanggan yang memilih layanan keamanan online cenderung churn?
- Apakah pelanggan yang memilih layanan internet tertentu cenderung churn?
- Apakah pelanggan yang memilih metode pembayaran tertentu cenderung churn?


Untuk menjawab pertanyaan pertama yaitu apakah pelanggan yang dengan contract kerja tertentu cenderung churn, kita akan membuat bar plot untuk melihat jumlah pelanggan berdasarkan jenis kontrak. Kita akan membandingkan jumlah pelanggan yang churn dan tidak churn berdasarkan jenis kontrak. Dengan menggunakan `.barplot()` dari Seaborn, kita bisa membuat visualisasi yang jelas dan mudah dipahami. Gambar 4 menunjukkan hasil dari visualisasi tersebut.



Gambar 4: Jumlah Pelanggan Churn Berdasarkan Jenis Kontrak

Dari Gambar 4 dapat dilihat bahwa pelanggan dengan kontrak "Month-to-month" memiliki jumlah churn yang paling tinggi dibandingkan dengan kontrak "One year" dan "Two year". Hal ini menunjukkan bahwa pelanggan yang memilih kontrak bulanan cenderung lebih sering berhenti berlangganan dibandingkan dengan pelanggan yang memilih kontrak tahunan atau dua tahunan.


Untuk pertanyaan kedua yaitu apakah pelanggan yang memilih langganan dengan paket bantuan TechSupport cenderung churn, kita akan membuat bar plot untuk melihat jumlah pelanggan berdasarkan pilihan TechSupport. Kita akan membandingkan jumlah pelanggan yang churn dan tidak churn berdasarkan pilihan TechSupport. Gambar 5 menunjukkan hasil dari visualisasi tersebut.



Gambar 5: Jumlah Pelanggan Churn Berdasarkan Pilihan TechSupport

Dari Gambar 5 dapat dilihat bahwa pelanggan yang memilih untuk menggunakan layanan TechSupport memiliki jumlah churn yang lebih rendah dibandingkan dengan pelanggan yang tidak menggunakan layanan TechSupport. Hal ini menunjukkan bahwa layanan TechSupport dapat membantu mengurangi tingkat churn pelanggan.


Untuk pertanyaan ketiga yaitu apakah pelanggan yang memilih layanan keamanan online cenderung churn, kita akan membuat bar plot untuk melihat jumlah pelanggan berdasarkan pilihan OnlineSecurity. Kita akan membandingkan jumlah pelanggan yang churn dan tidak churn berdasarkan pilihan OnlineSecurity. Gambar 6 menunjukkan hasil dari visualisasi tersebut.



Gambar 6: Jumlah Pelanggan Churn Berdasarkan Pilihan OnlineSecurity

Dari Gambar 6 dapat dilihat bahwa pelanggan yang memilih untuk menggunakan layanan OnlineSecurity memiliki jumlah churn yang lebih rendah dibandingkan dengan pelanggan yang tidak menggunakan layanan OnlineSecurity. Hal ini menunjukkan bahwa layanan OnlineSecurity dapat membantu mengurangi tingkat churn pelanggan.


Untuk pertanyaan keempat yaitu apakah pelanggan yang memilih layanan internet tertentu cenderung churn, kita akan membuat bar plot untuk melihat jumlah pelanggan berdasarkan jenis layanan internet. Kita akan membandingkan jumlah pelanggan yang churn dan tidak churn berdasarkan jenis layanan internet. Gambar 7 menunjukkan hasil dari visualisasi tersebut.



Gambar 7: Jumlah Pelanggan Churn Berdasarkan Jenis Layanan Internet

Dari Gambar 7 dapat dilihat bahwa pelanggan yang menggunakan layanan internet "Fiber optic" memiliki jumlah churn yang paling tinggi dibandingkan dengan pelanggan yang menggunakan layanan "DSL" atau "No". Hal ini menunjukkan bahwa pelanggan yang menggunakan layanan internet Fiber optic cenderung lebih sering berhenti berlangganan dibandingkan dengan pelanggan yang menggunakan layanan DSL atau tidak menggunakan layanan internet.

Untuk pertanyaan terakhir yaitu apakah pelanggan yang memilih metode pembayaran tertentu cenderung churn, kita akan membuat bar plot untuk melihat jumlah pelanggan berdasarkan metode pembayaran. Kita akan membandingkan jumlah pelanggan yang churn dan tidak churn berdasarkan metode pembayaran. Gambar 8 menunjukkan hasil dari visualisasi tersebut.



Gambar 8: Jumlah Pelanggan Churn Berdasarkan Metode Pembayaran

Dari Gambar 8 dapat dilihat bahwa pelanggan yang menggunakan metode pembayaran "Electronic check" memiliki jumlah churn yang paling tinggi dibandingkan dengan metode pembayaran lainnya. Hal ini menunjukkan bahwa pelanggan yang menggunakan metode pembayaran Electronic check cenderung lebih sering berhenti berlangganan dibandingkan dengan pelanggan yang menggunakan metode pembayaran lainnya.

Dari hasil analisa diatas kita tidak hanya mendapatkan fitur yang relevan dalam membangun model klasifikasi, tetapi juga mendapatkan insight bisnis yang dapat digunakan untuk meningkatkan retensi pelanggan. Adapun insight yang didapatkan dari analisis fitur kategorikal ini adalah sebagai berikut:


- Pelanggan dengan kontrak "Month-to-month" cenderung lebih sering berhenti berlangganan dibandingkan dengan pelanggan yang bekerja dengan kontrak tahunan atau dua tahunan.
- Layanan TechSupport dapat membantu mengurangi tingkat churn pelanggan.
- Layanan OnlineSecurity dapat membantu mengurangi tingkat churn pelanggan.
- Pelanggan yang menggunakan layanan internet "Fiber optic" cenderung lebih sering berhenti berlangganan dibandingkan dengan pelanggan yang menggunakan layanan DSL atau tidak menggunakan layanan internet.

- Pelanggan yang menggunakan metode pembayaran "Electronic check" cenderung lebih sering berhenti berlangganan dibandingkan dengan pelanggan yang menggunakan metode pembayaran lainnya.

Sehingga kita bisa membuat keputusan bisnis yang lebih baik berdasarkan hasil analisis ini. Adapun implikasi bisnisnya dari insight yang dihasilkan adalah sebagai berikut:

- Perusahaan dapat meningkatkan layanan TechSupport untuk membantu mengurangi tingkat churn pelanggan.
- Perusahaan dapat meningkatkan layanan OnlineSecurity untuk membantu mengurangi tingkat churn pelanggan.
- Perusahaan dapat mempertimbangkan untuk meningkatkan kualitas layanan internet Fiber optic untuk mengurangi tingkat churn pelanggan. Ataupun mengurangi biaya langganan untuk pelanggan yang menggunakan layanan internet Fiber optic.
- Perusahaan dapat mempertimbangkan untuk menawarkan metode pembayaran yang lebih fleksibel kepada pelanggan yang menggunakan metode pembayaran Electronic check.
- Perusahaan dapat melakukan penawaran khusus atau promosi untuk pelanggan yang masih bekerja dengan kontrak "Month-to-month" untuk meningkatkan retensi pelanggan.

Selain insight dan implikasi bisnis diatas, kita juga dapat fitur yang relevan untuk digunakan pada feature selection pada model klasifikasi kita nantinya. Namun sebelumnya kita juga perlu tahu korelasi antar fitur kategorikal ini agar kita mengetahui fitur apa saja yang redundant, Adapun kita akan menggunakan Cramer V yang sudah kita dapatkan tadi untuk menghitung korelasi antar fitur kategorikal. Cramer V adalah ukuran asosiasi antara dua variabel kategorikal yang berkisar antara 0 (tidak ada asosiasi) hingga 1 (asosiasi sempurna). Kita akan membuat matriks korelasi menggunakan Cramer V untuk melihat hubungan antar fitur kategorikal. Gambar 9 menunjukkan hasil dari heatmap korelasi Cramer V antar fitur Kategorikal.



Gambar 9: Heatmap Korelasi Cramer V Antar Fitur Kategorikal

Dari Gambar 9 dapat dilihat bahwa terdapat beberapa fitur yang memiliki korelasi tinggi ditandai dengan warna yang lebih merah. Dan fitur-fitur yang memiliki korelasi rendah ditandai dengan warna yang lebih biru. Adapun dengan temuan ini kita bisa melakukan feature selection untuk memilih fitur-fitur yang relevan dan tidak redundant. Kita akan memilih fitur-fitur yang memiliki korelasi tinggi dengan target variabel Churn dan menghindari fitur-fitur yang memiliki korelasi tinggi satu sama lain.

3.3.2 Analisis Fitur Numerik

Analisis fitur numerik dilakukan untuk memahami distribusi dari setiap fitur numerik dalam dataset. Kita akan menggunakan visualisasi seperti histogram, lalu melihat heatmap korelasi untuk melihat hubungan antar fitur numerik. Kita juga akan melakukan analisis statistik untuk melihat apakah terdapat outliers pada fitur-fitur numerik.

Pertama-tama, kita akan melihat ukuran pemusatan dari setiap fitur numerik. Kita akan menggunakan `.describe()` untuk melihat ukuran pemusatan seperti mean, median, dan standar deviasi dari setiap fitur numerik. Dengan begitu kita bisa mendapatkan gambaran umum tentang distribusi dari setiap fitur numerik.

Listing 6: Ukuran Pemusatan Fitur Numerik


```
1 # Ukuran pemusatan fitur numerik
```

	tenure	MonthlyCharges	TotalCharges
count	7032.000000	7032.000000	7032.000000
mean	32.421786	64.798208	2283.300441
std	24.545260	30.085974	2266.771362
min	1.000000	18.250000	18.800000
25%	9.000000	35.587500	401.450000
50%	29.000000	70.350000	1397.475000
75%	55.000000	89.862500	3794.737500
max	72.000000	118.750000	8684.800000

Dari hasil ukuran pemusatan di atas, kita bisa melihat bahwa fitur "tenure" memiliki nilai rata-rata sekitar 32 bulan, dengan nilai minimum 1 bulan dan maksimum 72 bulan. Fitur "MonthlyCharges" memiliki nilai rata-rata sekitar 64.8, dengan nilai minimum 18.25 dan maksimum 118.75. Sedangkan fitur "TotalCharges" memiliki nilai rata-rata sekitar 2283.3, dengan nilai minimum 18.8 dan maksimum 8684.8.

Setelah di analisa fitur tenure nampaknya cocok untuk dilakukan binning, karena fitur ini merupakan fitur numerik yang memiliki informasi tentang lama berlangganan pelanggan. Kita akan melakukan binning pada fitur "tenure" untuk mengelompokkan pelanggan berdasarkan lama berlangganan mereka. Kita akan membuat 3 kelompok yaitu "0-12 bulan", "13-24 bulan", dan "25+bulan". Dengan begitu kita bisa melihat distribusi pelanggan berdasarkan lama berlangganan mereka.

Karena fitur tenure sudah kita putuskan untuk binning, maka selanjutnya kita akan cek tipe distribusi untuk fitur MonthlyCharges dan TotalCharges. Kita akan menggunakan histogram untuk melihat distribusi dari setiap fitur numerik. Dengan menggunakan .hist() kita bisa membuat histogram yang jelas dan mudah dipahami. Gambar 10 menunjukkan hasil dari histogram distribusi kedua fitur numerik.




Gambar 10: Histogram Distribusi Fitur Numerik

Dari Gambar 10 dapat dilihat bahwa fitur "MonthlyCharges" memiliki distribusi yang cenderung normal, dengan puncak di sekitar nilai 70. Sedangkan fitur "TotalCharges" memiliki distribusi yang cenderung skewed ke kanan, dengan puncak di sekitar nilai 1000. Hal

ini menunjukkan bahwa sebagian besar pelanggan memiliki total biaya yang relatif rendah, namun terdapat beberapa pelanggan yang memiliki total biaya yang sangat tinggi.


Selanjutnya kita akan melakukan analisis korelasi antar fitur numerik. Kita akan menggunakan heatmap untuk melihat hubungan antar fitur numerik. Dengan menggunakan `.heatmap()` dari Seaborn, kita bisa membuat visualisasi yang jelas dan mudah dipahami. Gambar 11 menunjukkan hasil dari heatmap korelasi antar fitur numerik.



Gambar 11: Heatmap Korelasi Antar Fitur Numerik

Dari Gambar 11 dapat dilihat bahwa terdapat korelasi yang cukup tinggi antara fitur "MonthlyCharges" dan "TotalCharges", dengan nilai korelasi sekitar 0.65. Hal ini menunjukkan bahwa semakin tinggi biaya bulanan yang dibayarkan oleh pelanggan, semakin tinggi pula total biaya yang dibayarkan selama berlangganan. Sedangkan fitur "tenure" memiliki korelasi yang rendah dengan kedua fitur numerik lainnya, yaitu "MonthlyCharges" dan "TotalCharges".

Kita juga akan melakukan analisis outliers pada fitur-fitur numerik. Kita akan menggunakan boxplot untuk melihat apakah terdapat outliers pada setiap fitur numerik. Dengan menggunakan `.boxplot()` dari Seaborn, kita bisa membuat visualisasi yang jelas dan mudah dipahami. Gambar 12 menunjukkan hasil dari boxplot outliers pada kedua fitur numerik.



Gambar 12: Boxplot Outliers Fitur Numerik

Dari Gambar 12 merupakan boxplot untuk fitur "MonthlyCharges" dan "TotalCharges" berdasarkan kategori "Churn". Dapat dilihat bahwa terdapat beberapa outliers pada kedua fitur numerik tersebut. Outliers ini dapat mempengaruhi hasil analisis dan model yang akan dibangun, sehingga perlu ditangani dengan baik. Kita bisa menghapus outliers tersebut atau menggunakan metode robust scaling untuk mengurangi pengaruh outliers pada model.

Selain itu kita juga mendapatkan bahwa pelanggan dengan biaya bulanan yang lebih tinggi cenderung untuk churn. Hal ini terlihat dari boxplot yang menunjukkan bahwa pelanggan yang churn memiliki biaya bulanan yang lebih tinggi dibandingkan dengan pelanggan yang tidak churn. Sedangkan untuk fitur "TotalCharges", kita tidak bisa menarik kesimpulan yang sama karena terdapat outliers yang cukup signifikan pada kedua kategori dan pada pelanggan yang churn berdasarkan totalcharges cukup datanya cukup tersebar sehingga tidak bisa ditarik kesimpulan yang signifikan.

Setelah melakukan analisis fitur numerik, kita mendapatkan beberapa insight yang dapat digunakan untuk meningkatkan retensi pelanggan. Adapun insight yang didapatkan dari analisis fitur numerik ini adalah sebagai berikut:

- Pelanggan dengan lama berlangganan yang lebih lama cenderung memiliki total biaya yang lebih tinggi.
- Pelanggan dengan biaya bulanan yang lebih tinggi cenderung memiliki total biaya yang lebih tinggi.
- Terdapat segmen highend pada fitur TotalCharges menandakan adanya pelanggan yang memiliki total biaya yang sangat tinggi.
- Pelanggan dengan biaya bulanan yang lebih tinggi cenderung untuk churn.

Sehingga kita bisa membuat keputusan bisnis yang lebih baik berdasarkan hasil analisis ini. Adapun implikasi bisnisnya dari insight yang dihasilkan adalah sebagai berikut:

- Perusahaan dapat mempertimbangkan untuk memberikan penawaran khusus atau promosi kepada pelanggan dengan lama berlangganan yang lebih lama untuk meningkatkan retensi pelanggan.
- Perusahaan dapat mempertimbangkan untuk memberikan penawaran khusus atau promosi kepada pelanggan dengan biaya bulanan yang lebih tinggi untuk meningkatkan retensi pelanggan.
- Perusahaan dapat mempertimbangkan untuk melakukan segmentasi pelanggan berdasarkan total biaya yang dibayarkan untuk meningkatkan retensi pelanggan.

Selain kita juga mendapatkan bahwa fitur tenure yang merupakan fitur numerik yang memiliki informasi tentang lama berlangganan pelanggan, dapat dilakukan binning untuk mengelompokkan pelanggan berdasarkan lama berlangganan mereka. Kita akan membuat 3 kelompok yaitu "0-12 bulan", "13-24 bulan", dan "25+bulan". Maka dengan ini kita bisa melakukan fitur engineering untuk membuat fitur baru yaitu "tenure_group" yang merupakan hasil binning dari fitur "tenure". Kita akan menggunakan `pd.cut()` untuk melakukan binning pada fitur "tenure". Dengan begitu kita bisa melihat distribusi pelanggan berdasarkan lama berlangganan mereka.

3.4 Feature Engineering

Setelah melakukan analisis terhadap fitur-fitur yang ada dalam dataset, kita akan melakukan feature engineering untuk membuat fitur-fitur baru yang dapat meningkatkan performa model klasifikasi yang akan dibangun. Feature engineering adalah proses menciptakan fitur-fitur baru dari fitur-fitur yang sudah ada untuk meningkatkan kemampuan model dalam memprediksi target variabel.

3.4.1 Binning Fitur Tenure

Pada analisa sebelumnya kita mendapatkan bahwa fitur tenure yang merupakan fitur numerik yang memiliki informasi tentang lama berlangganan pelanggan, dapat dilakukan binning untuk mengelompokkan pelanggan berdasarkan lama berlangganan mereka. Kita akan membuat 3 kelompok yaitu "0-12 bulan", "13-24 bulan", dan "25+bulan". Maka dengan ini kita bisa melakukan fitur engineering untuk membuat fitur baru yaitu "tenure_group" yang merupakan hasil binning dari fitur "tenure". Kita akan menggunakan `pd.cut()` untuk melakukan binning pada fitur "tenure". Dengan begitu kita bisa melihat distribusi pelanggan berdasarkan lama berlangganan mereka.

Listing 7: Feature Engineering Binning Fitur Tenure

```

1 # Output setelah binning
2 tenure_group
3
4 oneyear
5 threeyear
6 oneyear
7 threeyear

```

8 oneyear


Setelah binning berhasil, selanjutnya saya ingin menguji chi-square untuk melihat apakah fitur tenure_group ini signifikan terhadap target variabel Churn. Dengan begitu kita bisa mengetahui apakah fitur ini relevan untuk digunakan dalam model klasifikasi.

Listing 8: Uji Chi-Square Fitur Tenure Group

```
1 # Output uji chi-square
2 Chi2: 807.5820584283829, p-value: 4.32298939601873e-176, dof: 2
3 Ada hubungan signifikan antara tenure dan Churn
```

Dari hasil uji chi-square di atas, kita mendapatkan nilai Chi2 sebesar 807.58 dengan p-value yang sangat kecil yaitu 4.32e-176. Hal ini menunjukkan bahwa terdapat hubungan yang signifikan antara fitur tenure_group dan target variabel Churn. Sehingga fitur tenure_group ini relevan untuk digunakan dalam model klasifikasi.

Selanjutnya saya juga ingin melihat boxplotnya untuk menggali lebih dalam tentang fitur tenure_group ini. Dengan menggunakan .boxplot() dari Seaborn, kita bisa membuat visualisasi yang jelas dan mudah dipahami. Gambar 13 menunjukkan hasil dari boxplot fitur tenure_group berdasarkan kategori Churn.



Gambar 13: Boxplot Fitur Tenure Group Berdasarkan Kategori Churn

Dari Gambar 13 dapat dilihat bahwa pelanggan yang memiliki lama berlangganan 0-12 bulan cenderung memiliki jumlah churn yang lebih tinggi dibandingkan dengan pelanggan yang memiliki lama berlangganan 13-24 bulan dan 25+bulan. Hal ini menunjukkan bahwa pelanggan yang baru berlangganan cenderung lebih sering berhenti berlangganan dibandingkan dengan pelanggan yang sudah lama berlangganan.

3.4.2 Binning fitur dengan Uji Chi-Square lemah

Selain fitur `tenure_group`, kita juga akan melakukan binning pada fitur `Dependents`, `partner`, dan `SeniorCitizen`. Saya memutuskan untuk membuat fitur baru bernama `is_married` dengan kondisi jika `Dependents` atau `Partner` atau `SeniorCitizen` bernilai "Yes" maka `is_married` bernilai "Yes" dan jika tidak maka bernilai "No". Dengan begitu kita bisa melihat distribusi pelanggan berdasarkan status pernikahan mereka.

Listing 9: Feature Engineering Binning

```
1 # Output setelah binning
2
3      is_married
4 1      4313
5 0      2719
6 Name: count, dtype: int64
```

Dengan begitu kita telah berhasil membuat fitur baru bernama `is_married` yang merupakan hasil binning dari fitur `Dependents`, `Partner`, dan `SeniorCitizen`.

3.5 Feature Selection

Setelah melakukan feature engineering, kita akan melakukan feature selection untuk memilih fitur-fitur yang relevan dan tidak redundant. Feature selection adalah proses memilih fitur-fitur yang paling penting untuk digunakan dalam model klasifikasi. Kita akan menggunakan metode chi-square untuk memilih fitur-fitur yang relevan dengan target variabel `Churn`.

Pertama tama `customerID` akan kita buang karena fitur ini tidak relevan untuk digunakan dalam model klasifikasi. Fitur ini hanya berfungsi sebagai identifikasi unik untuk setiap pelanggan dan tidak memberikan informasi yang berguna untuk memprediksi target variabel `Churn`.

3.5.1 Berdasarkan Uji Chi-Square

Kita akan melakukan uji chi-square untuk setiap fitur kategorikal yang ada dalam dataset. Dan telah melakukan feature engineering berdasarkan uji chi-square yang telah dilakukan sebelumnya. Dengan begitu otomatis fitur-fitur ini akan dibuang :

- `Dependents`
- `Partner`
- `SeniorCitizen`
- `tenure`
- `Gender`
- `PhoneService`
- `MultipleLines`

Dengan membuang fitur yang tidak relevan, kita akan mendapatkan fitur-fitur yang lebih fokus dan dapat meningkatkan performa model klasifikasi.

4 Pengujian dan analisis

4.1 Pengujian Sistem

5 Kesimpulan dan Saran